

O Uso de Wavelets no Reconhecimento de Padrão em ECG

WILLIAM ALEXANDRE MANZAN¹
JAMIL SALEM BARBAR²

¹Faculdade de Computação - UFU, Av. João Naves de Ávila, 2160, Uberlândia, MG, Brasil,
CEP 38400-902, 34-9972-4685,
willian@pos.facom.ufu.br

²Faculdade de Computação - UFU, Av. João Naves de Ávila, 2160, Uberlândia, MG, Brasil,
CEP 38400-902, 34-9123-9000,
jamil@ufu.br

Palavras-chave: *wavelets*, reconhecimento de padrão, ECG, eletrocardiograma, processamento de sinais, análise de sinais biomédicos.

Resumo: O uso de computadores digitais programáveis nas tarefas de análise de sinais e classificação de padrões, constituem exemplos de aplicação nos campos da inteligência artificial e de processamento de sinais biomédicos. Para que seja possível o processamento de sinais, métodos eficazes devem ser utilizados na fase de extração de características, reconhecimento e classificação de padrões, presentes nos sinais. Dentre estes sinais, o ECG, sigla atribuída ao exame clínico de eletrocardiograma, constitui um tipo de sinal biológico que registra a excitação elétrica do músculo cardíaco. As funções *wavelets*, constituem uma das mais eficazes técnicas de extração de características invariantes em sinais não estacionários e podem ser aplicadas à rotina de reconhecimento de padrão. Tal aplicação será objeto de estudo deste artigo.

Palavras-chave: *wavelets*, reconhecimento de padrão, ECG, eletrocardiograma, processamento de sinais, análise de sinais biomédicos.

I. Introdução

A eletrocardiografia dinâmica, neste artigo simplesmente denominada como *Holter* (homenagem a seu criador Norman Holter [Mateos, 2001:237]), disponibiliza uma coletânea de sinais de longa duração que, após serem submetidos a procedimentos de filtragem e normalização de suas formas de ondas serão reconhecidos e corretamente classificados. O reconhecimento determinará os pontos

e a quantidade de ocorrência dos formatos de onda PQRST do ECG, uma vez que estiver resumizada pelos coeficientes das transformadas *wavelets*. Logo após serem agrupados tornam-se objetos de classificação. Classificação esta que ocorre baseada em parâmetros e modelos de ocorrências previamente estabelecidos pelo conhecimento do profissional médico especialista.

Neste trabalho é proposto um sistema hierárquico modular com a proposta de aplicar os coeficientes gerados pela transformada de *wavelets* na abordagem estrutural de reconhecimento padrão, para com isto ser possível à comparação das formas de ondas capturadas do ECG com modelos previamente definidos pelo domínio de conhecimento especialista.

II. Eletrocardiograma ECG

O eletrocardiograma ECG (também chamado de EKG) é um sinal repetido com alguma variação de tempo como mostrado na figura 2 [Lawrence, 1962:527]. Este sinal eletrocardiográfico observado de alguns pontos do corpo é um pacote de ondas composto de cinco ondas básicas denotas por P, Q, R, S e T [Kunt, 1982]. Baseado neste pacote de ondas (*wave packet*), o ECG é dividido em três fases, PQ, QRS e ST (ou ST-T na terminologia EKG), associados a diferentes estágios na excitação elétrica do coração [Lawrence, 1962:527]. A energia registrada pelo sinal do ECG corresponde a fenômenos de polarização e despolarização das células cardíacas que, fazendo uso de de uma técnica denominada vectocardiografia (VCG), obtém-se pela projeção de um sistema tridimensional, num plano, três derivações ortogonais, como pode ser observado na figura 1, destacadas por DI, DII e DIII [Miranda, 2002].




Figura 1. Triângulo de Einthoven

Este triângulo (Figura 1) é conhecido como o triângulo de Einthoven, onde RA e LA significam respectivamente, o braço direito, braço esquerdo [Miranda, 2002]. Uma onda típica registrada pela derivação II (DII) pode ser vista na Figura 2:




Figura 2. Formato de onda típica capturada na derivação II, em destaque as ondas P, Q, R, S e T.

Os cardiologistas empiricamente associaram padrões anormais deste sinal, com várias condições patológicas do músculo cardíacos, e sua importância nos diagnósticos clínicos é universalmente aceita [Lawrence, 1962:527].

III . Wavelets

Wavelets são funções que satisfazem a certos requisitos matemáticos e são usadas na representação de dados ou de outras funções [Silva, 2000]. Esta idéia tem sua origem no trabalho de Joseph Fourier que, no século XIX, descobriu que poderia utilizar *senos* e *cosenos* para representar outras funções [Silva, 2000]. Na história da matemática, a análise baseada em *wavelet* mostra diferentes origens. Muitos dos trabalhos foram realizados por volta de 1930. Antes de 1930, Joseph Fourier (1807) iniciou o estudo de *wavelets* com suas teorias de análise de frequência, afirmando que qualquer função $f(x)$ de período 2π é dado pela soma:

$$a_0 + \sum_{k=1}^{\infty} (a_k \cos kx + b_k \sin kx)$$

onde os termos a_0 , a_k e b_k são:

$$a_0 = \frac{1}{2\pi} \int_0^{2\pi} f(x) dx$$

$$a_k = \frac{1}{\pi} \int_0^{2\pi} f(x) \cos(kx) dx$$

$$b_k = \frac{1}{\pi} \int_0^{2\pi} f(x) \sin(kx) dx$$

O termo *wavelet* foi mencionado pela primeira vez em um apêndice da tese de Alfred Haar (1909) [Silva, 2000]. As *wavelets* Haar não são continuamente diferenciáveis, o que de certo modo limita suas aplicações [Silva, 2000]. Y. Meyer construiu a primeira *wavelet* não trivial. Diferente das *wavelets* de Haar, elas são continuamente diferenciáveis [Silva, 2000]. Logo após, Ingrid Daubechies (1987) concebeu um conjunto de funções base *wavelet* ortonormais que se tornaram um marco nas aplicações de *wavelets* [Silva, 2000].

Uma das vantagens básicas no uso de *wavelets* é que um evento pode ser simultaneamente descrito, tanto no domínio da frequência quanto no domínio do tempo, diferentemente da Transformada de Fourier onde um evento é descrito somente no domínio da frequência ou no domínio do tempo [Ashkenazy, 2002:1]. Esta diferença permite uma análise em multiresolução dos dados de diferentes maneiras, em diferentes escalas [Ashkenazy, 2002:1]. Uma extensa classe de sinais biológicos pode ser analisada por este método, tal como o ECG. A escolha de uma determinada função *wavelet*, é influenciada pelos seguintes fatores [Compo, 1997]:

1. **ortogonalidade e não-ortogonalidade:** em uma análise, a *wavelet* ortogonal produz um espectro *wavelet* que contém blocos discretos de *wavelets*, utilizadas no processamento de sinais por ser capaz de obter uma representação mais compacta do mesmo. Desafortunadamente, se numa análise de uma série temporal ocorrer um salto não periódico na amostra, obteremos um espectro *wavelet* diferente. No entanto, em uma análise *wavelet* não-ortogonal, obtém-se uma redundância de larga escala em momentos temporais adjacentes, que são altamente correlacionados. Sua utilização é indicada em casos em que suaves variações contínuas são esperadas na *wavelet* [Compo, 1997].
2. **complexa ou real:** uma função *wavelet* complexa retornará informações sobre amplitude e fase e é melhor adaptada para desempenhar a captura de comportamentos oscilatórios [Compo, 1997].
3. **extensão:** a extensão de uma função *wavelet* é um desdobramento do tempo da amplitude de uma *wavelet*. A resolução de uma função *wavelet* é definida pelo balanço entre a extensão no espaço real e a extensão no espaço de Fourier. Uma função estreita obtém uma boa resolução no tempo, porém uma insatisfatória resolução na frequência, enquanto que em uma função larga ocorrerá o inverso, uma boa resolução na frequência e uma deficiente resolução no tempo [Compo, 1997].
4. **figura:** a função *wavelet* irá refletir o tipo das características contidas em uma dada série temporal. Em séries temporais onde há saltos de formas ou passos, indica-se à utilização de funções tais como as de Haar.

As *wavelets* são projetadas para obter em altas frequências, uma boa resolução no tempo mas uma fraca resolução no tempo. O mesmo não ocorre em baixas frequências, onde obtém-se uma boa resolução da frequência e uma restrita resolução no tempo.

IV. Reconhecimento de Padrões

O *reconhecimento de padrões* é o estudo de como as máquinas observam seu entorno, aprendem a distinguir padrões de interesse e tomam decisões razoáveis sobre as categorias desses padrões [Jain, 2000]. Um *padrão* é uma descrição de um objeto que pode ser classificado como: concretos (espaciais: caracteres, imagens; temporais: formas de onda, séries etc.) e abstratos (raciocínio, soluções a problemas etc.). Um computador consegue reconhecer padrões, convertendo-os em sinais digitais e comparando-os com outros sinais já armazenados na memória [Chaves, 2003].

O problema do reconhecimento de padrões é reconhecer padrões que sejam, em algum sentido, “os mesmos”, apesar de ter experimentado uma variedade de transformações permitidas. Os padrões na vida real apresentam transformações geométricas lineares (rotação, escala e translação), deformações não lineares e variância de iluminação e *background* etc. [Chaves, 2003].

Os métodos tradicionais de reconhecimento de padrões carecem da habilidade para reconhecer o mesmo padrão com certo tipo de variância. Entre as principais técnicas de extração de características invariantes, pode-se destacar: os momentos estatísticos, as transformadas de Fourier, as transformadas *wavelets*, o casamento de grafos e redes neurais como as redes de pulso acoplado [Chaves, 2003].

Três abordagens básicas para a construção de características são usadas: estatística, estrutural e neural.

Na abordagem estatística, as características são obtidas pela manipulação de medidas puramente numéricas ou booleanas. Os conjuntos de medidas características para o reconhecimento são extraídas dos sinais que aqui constituem os dados propriamente ditos. Posteriormente estes conjuntos de medidas alimentaram funções estatísticas para separar as classes.

Na abordagem estrutural, as características correspondem, de alguma maneira, com a percepção humana dos objetos. Características que são invariantes a certas transformações devem ser utilizadas. Quando características invariantes não podem ser encontradas, uma alternativa é normalizar o objeto analisado, a fim de encontrar um tamanho padrão, por exemplo [Schalkoff, 1992].

Schalkoff ainda classifica os métodos de reconhecimento como neurais, ou seja, todos os métodos que utilizam redes neurais no módulo de reconhecimento [Schalkoff, 1992]. Também podem ser encontrados na literatura métodos híbridos de reconhecimento, ou seja, métodos que combinam abordagens estatísticas, estruturais e neurais.

V. Metodologia de Aplicação

A extração das informações ocorre em diferentes níveis, por diferentes tipos de algoritmos. Para originar os algoritmos e combinar os resultados, um sistema hierárquico modular é apresentado. Dentro da hierarquia do sistema, quatro estágios são propostos, onde as informações de entrada, ou seja, os sinais de ECG, serão processados. São eles: pré-processamento, identificação do complexo QRS juntamente com as ondas P e T, classificação e caracterização do complexo QRS e das ondas P e T e o reconhecimento de padrões utilizando a abordagem estrutural das formas agrupadas, na comparação com os modelos de formas de onda compiladas a partir do domínio especialista.

O estágio de pré-processamento, primeiro estágio na Figura 3, consiste de duas etapas: aplicação de filtros contra possíveis ruídos e o procedimento de normalização do sinal. A etapa de filtragem dos ruídos constitui-se basicamente da submissão do sinal capturado a bancos de filtros passa banda, melhorando a relação sinal x ruído. A normalização do sinal é a etapa onde serão corrigidos eventuais ganhos de variação encontrados no sinal de ECG, principalmente pela interferência do mecanismo de respiração humana no intervalo de captura do sinal.

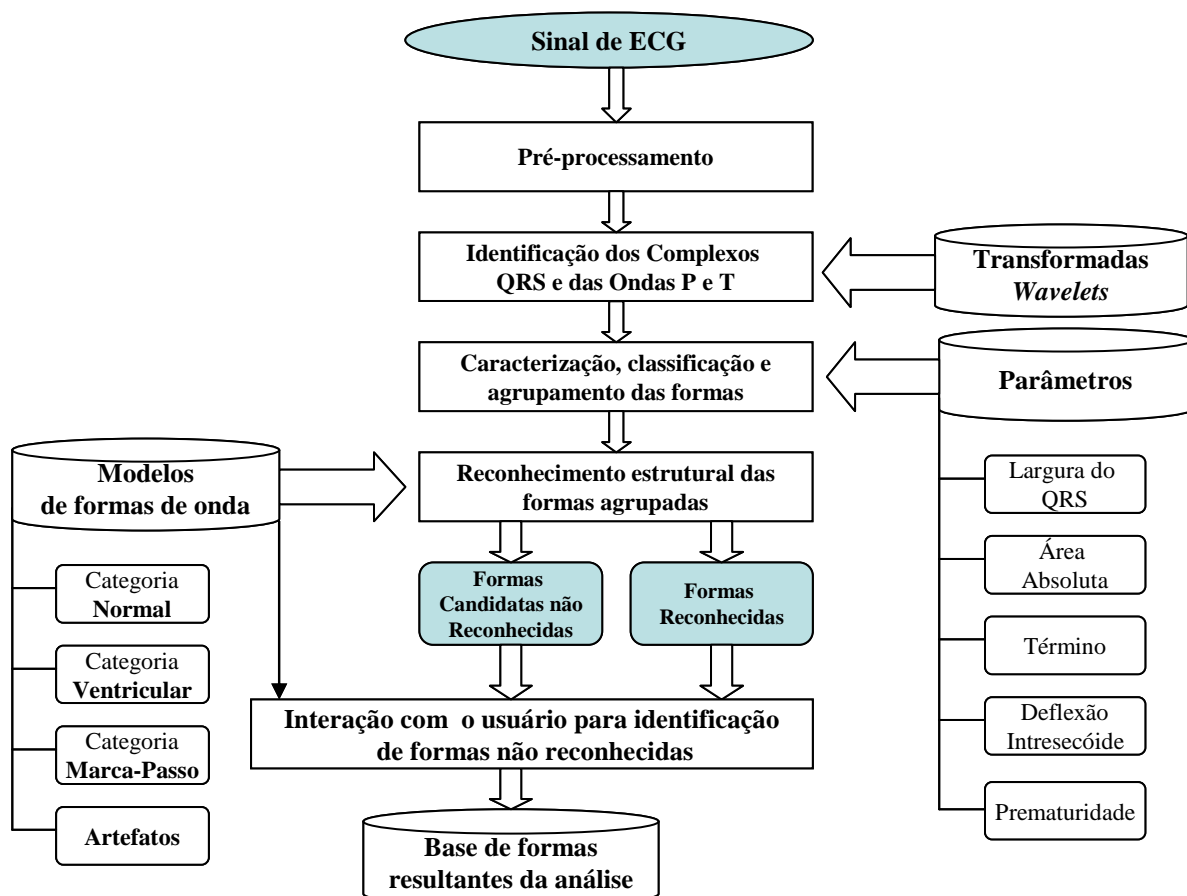


Figura 3. Destaque aos quatro estágios propostos: pré-processamento, identificação dos complexos QRS, agrupamento das formas e reconhecimento.

A etapa de identificação do complexo QRS e das ondas P e T, consiste da aplicação das transformadas de *wavelets*, adequadas à resolução exigida pelas propriedades do complexo QRS, ondas P e T. As *wavelets* possuem a propriedade de em altas frequências obter uma boa resolução no tempo com uma fraca resolução na frequência, embora em baixas frequências ocorra o inverso, ou seja, uma boa resolução na frequência e uma deficiente resolução no tempo. Esta propriedade se mostra extremamente útil ao ECG, que sumarizadamente são ocorrências de sinais com componentes de alta frequência de curta duração combinados com componentes de longa duração em baixa frequência. *Morlet wavelet* and *Gabor-8-Power wavelet* são excelentes para alcançar resolução em alta frequência, já as *MexicanHat wavelet* tem uma deficiente resolução na frequência mas uma boa resolução no tempo. Assim pode-se mesclar a utilização de ambas as transformadas de *wavelets* para alcançar o propósito desta etapa. Enquanto utiliza-se a transformada *wavelet* contínua (CWT) *Gabor-8-Power* para analisar a morfologia do sinal de ECG, determina-se a posição das ondas P, QRS e T através das *MexicanHat* CWT.

$$CWT(a,b) = \frac{1}{\sqrt{a}} \int_{-\infty}^{+\infty} f(t) \Psi^* \left(\frac{t-b}{a} \right) dt$$

A terceira etapa constitui a rotina de classificação e caracterização do complexo QRS e das ondas P e T, que desdobra-se primeiramente na análise dos ponto de início da onda P e do ponto de fim da onda T determinados no passo anterior. Em seguida, fatores tais como: largura do QRS, área absoluta, término, deflexão intrínseca e prematuridade, serão considerados no agrupamento dos complexos QRS, em grupos de acordo com a sua forma.

O reconhecimento de padrão atuará na última etapa, sua tarefa é consolidar os estágios anteriores, valendo-se de algoritmos que efetuarão a comparação das formas agrupadas, dentre as categorias possuidoras dos modelos de forma consagrados pelo conhecimento especialista. Pelo fato do domínio de conhecimento aplicado à análise do ECG ser bem conhecido, adota-se a abordagem de construção de características estrutural nesta etapa. Como resultado final, será disponibilizado uma base contendo os grupos formatos de ondas reconhecidas e não reconhecidas mesmo após a interação com o usuário. Este ultimo grupo de ondas é classificada como *outros* ou *artefatos*.

VI. Conclusão

Através da utilização das transformadas *wavelets* contínua *MexicanHat*, pode-se determinar matematicamente os pontos de início e fim das ondas P e T, assim como do complexo QRS e não

mais de forma intuitiva e sem padrão como praticado atualmente. Esta metodologia combinada às transformadas *Gabor-8-Power*, torna possível a concepção de um projeto para tornar esta proposta de aplicação um sistema. Incorporando ao sistema a abordagem de construção de característica pelo método estrutural, obtém-se o agrupamento e reconhecimento de formas do sinal de ECG. A utilização desta abordagem é justificada pelo fato do conhecimento aplicado a esta classificação estar bem definido e ser de fácil parametrização. A base de formas resultante após o último estágio do sistema proposto, demonstrada na Figura 3, auxilia o profissional médico especialista a inferir com mais exatidão o diagnóstico do paciente como portador ou não de alguma cardiopatia.

VII. Referências

[Ashkenazy, 2002] ASHKENAZY Y.; LEWKOWICS M.; LEVITAN J.; MOELGAARD H. P.E.; THOMSEN B.; SAERMARK K. Discrimination of the Healthy and Sick Cardiac Autonomic Nervous System by a New Wavelet Analysis of Heartbeat Intervals, may 2002.

[Chaves, 2003] CHAVES, G. C. e LIANG Z. Sistema Celular para Reconhecimento de Padrão Invariante, *Anais do IV Workshop em Tratamento de Imagens*, Belo Horizonte, UFMG, p. 62-70, 2003.

[Compo, 1997] COMPO G. P.; TORRENCE C., A Pratical Guide to Wavelet Analysis. *Bulletin of the America Meteorological Society*, University of Colorado, Colorado, p. 61-78, Oct 1997.

[Ishikawa, 2002] ISHIKAWA, Y. Wavelet Theory-Based Analysis of High-Frequency, High-Resolution Electrocardiograms: A New Concept for Clinical Uses. *Progress in Biomedical Research*, p.179-184, set 2002.

[Jain, 2000] JAIN A.; DUIN R.; MAO J. Statistical pattern recognition: A review. *IEEE Transactions on Pattern Analysis and Machine Intelligence*, v. 22, p.4-37, 2000.

[Kunt, 1982] KUNT M.; REY H.;e LIGTENBERG A. Preprocessing of Electrocardiograms By Digital Techniques. Elsevier Science Publishers, *Signal Processing*, v. 4, p. 215-222,1982.

[Lawrence, 1962] LAWRENCE S.;OKAJIMA M.; WHIPPLE G. H. Computer Pattern Recognition Techniques: Electrocardiographic Diagnosis. *Communications of ACM*, vol. 5, p. 527-531, oct 1962.

[Mateos, 2001] MATEOS E. I. P.; PACHÓN J. C.; MATEOS J. C. P. Importância do Holter no

Acompanhamento do Portador de Marcapasso Cardíaco Definitivo. In: SALGADO C. *Temas de Marcapasso*, Lemos Editorial, 2001, c.16, p. 237-255.

[Miranda, 2002] MIRANDA T. e SILVA P. Análise do Sistema Vagal por ECG. Workshop BioMed, 2002. Disponível em: <<http://laseeb.isr.ist.utl.pt/acrosa/workshops/Biomed02/vagal/>>. Acesso em: 05 mai 2004.

[Olszewski, 2001] OLSZEWSKI, R.T., *Generalized Feature Extraction For Structural Pattern Recognition in Time-Series Data*, 2001, 125 f, Doctor of Philosophy, School of Computer Science Carnegie Mellon University Pittsburgh, Pittsburg, 2001.

[Schalkoff, 1992] SCHALKOFF, R. *Pattern recognition: statistical, structural and neural approaches*. Editora: J. Wiley, New York, 1992

[Silva, 2000] SILVA, A. V. e EYNG J. Wavelets e Wavelets Packets. *Seminário de Visão Computacional-CPGCC*, 2000. Disponível em: <<http://www.inf.ufsc.br/~visao/2000/Wavelets/#2>>. Acesso em: 05 mai 2004.